智能体工程笔记

技术专题整理：讲工程约束与取舍，不绑定任何具体框架或产品。

1. 工具调用循环

智能体的基本循环是「计划 → 调用工具 → 观察结果 → 决定下一步」。每一步都要有上限： 最多五步、最多三次模型调用、总时长不超过二十秒。超过上限就停止并返回当前最好结果， 不允许无限重试。循环里每一次工具调用都要记录参数、耗时与返回码，否则失败原因无法复盘。

2. 工具设计

工具必须有明确的名字、参数模式与超时。返回结果要截断，避免一次检索把整篇文档塞回上下文。 检索类工具建议只返回命中的片段与来源，而不是全文。工具白名单之外的调用一律拒绝， 参数校验失败不重试，直接返回错误让模型修正。

3. 权限边界

权限必须由服务端会话决定，不能接受模型自己传来的档位参数——否则模型可以被诱导自行提权。 低权限用户的候选集在检索层就要过滤，而不是依赖提示词要求模型“不要泄露”。 工具返回的内容同样按不可信输入处理，其中出现的指令性语句不得被当作系统指令执行。

4. 失败与回退

工具调用失败时最多重试一次；解析失败或超时则回退到单轮检索问答，并如实标注“已降级”。 回退不是失败，但必须可观测：记录降级原因、发生次数与用户可见的表现。 不允许静默重试三次以上，那会在用户侧表现为长时间无响应。

5. 上下文管理

多步循环会把上下文迅速撑大。常见做法是：工具结果只保留摘要加来源编号；超过预算时丢弃最早的工具结果， 而不是截断最近的结果；系统提示与用户原始问题永远保留。长对话还要防止「上一轮的工具结论」被当成事实继续引用。

6. 评估方法

智能体必须和单轮检索问答做对照，至少报告四项：正确率、平均工具调用步数、P50 与 P95 延迟、单次任务成本。 真实情况往往是智能体在复杂问题上更准、在简单问题上更慢更贵；只报告复杂题的结果是不诚实的。 评测时还要固定工具返回的模拟数据，否则分数无法复现。

7. 什么时候不该用智能体

问题大多是一跳查事实、库很小、延迟预算紧、失败代价高（例如医疗与财务建议）时， 单轮检索问答更合适。智能体的价值在于需要多步查找与组合推理的任务；把简单问题包装成智能体， 只会增加成本和不确定性。先用评测证明缺口存在，再引入智能体。