星澜 AI 推理平台运维纪要

本文件是**虚构的演示语料**：公司「星澜科技」、平台「Lumen」及全部数字均为自编， 仅用于本地检索链路演示与评测，不代表任何真实企业或事件。

1. 平台概况

Lumen 平台承载星澜科技的对话式推理服务，线上模型为 70 亿参数聊天模型，权重以 int8 量化部署，推理引擎为 vLLM。GPU 资源池共 12 张卡：8 张 A100 40GB 承担线上流量，4 张 L40 用于灰度与压测。

工作日峰值为每秒 1200 次请求，平均单次请求消耗 1.8k tokens，按内部计价约合 0.0042 元一次， 每月推理预算 12 万元，超支需向平台组提预算变更单。

2. 延迟与容量预算

首 token 延迟 P99 预算为 800 毫秒，整段回复 P99 预算为 4.5 秒。KV cache 命中率低于 60% 时 判定为会话切分不合理，需要调整滑动窗口长度。单卡并发上限设为 32 条序列，超出后请求进入排队队列，排队时间超过 2 秒即计入过载指标。

3. 发布与回滚

模型或推理引擎上线一律走灰度：先 5% 流量，观察 30 分钟；再 25%，再观察 30 分钟；最后 100%。任一档触发下列条件之一必须立即回滚到上一稳定版本，并在发布记录中写明回滚版本号与影响范围：

- 错误率连续 5 分钟高于 1%；
- 首 token 延迟 P99 连续 5 分钟高于 1.2 秒；
- 抽检输出出现乱码、重复或工具调用格式非法，且比例高于千分之三。

4. 事故记录 2025-03-14（P1）

当日 14:07 监控告警：输出乱码率升至 2.4%。根因是灰度批次使用了新版分词器，而回滚批次仍为旧版，两端词表不一致导致 token 对齐错位。14:24 完成全量回滚，服务恢复，总影响时长 17 分钟。

复盘要求：故障恢复后 2 个工作日内提交复盘报告，明确「分词器版本必须与模型权重一起打镜像」这一长期修复项；值班人员在 10 分钟内响应、30 分钟内建立故障协作群，每 20 分钟同步一次进展。

5. 日常巡检

值班每日 09:30 检查三项：显存占用是否超过 90%、排队时长中位数是否超过 200 毫秒、 以及昨日缓存命中率是否低于周均值 10% 以上。发现异常在巡检记录中登记，连续两天异常升级为 P3 工单， 应在 4 个工作小时内响应并在下次例会上同步处理情况。

6. 发布窗口

常规上线只允许在每周二与每周四 20:00 至 23:00 进行，周末、法定节假日以及大促期间禁止上线。 紧急修复可以走加急通道，但需要平台组负责人与业务方各一名确认，并在上线后 24 小时内补齐变更单。 每

次上线必须记录：版本号、灰度各档观测数据、回滚版本号占位、以及验证人姓名。

7. 数据与隐私

请求日志保留 14 天，包含用户原始输入的日志在脱敏后保留 30 天，超过期限由清理任务自动删除。 任何线上输入默认不得用于训练，如需用于训练必须取得单独授权并做去标识化处理。 日志导出需要审批，导出的文件必须登记用途与删除时间。 压测数据一律使用自编语料，禁止把学校、客户或合作方的文档直接搬进测试环境。

8. 容量演练与降级预案

每季度执行一次 1.5 倍峰值压测，压测环境与线上隔离。当实时 QPS 超过 1500 时按顺序降级： 先关闭长文本重排以节省算力，再把超出容量的请求引导到答案缓存，最后把单次最大输出从 1024 tokens 压到 512 tokens。降级动作必须可观测：每次触发都要在告警渠道留下开始与结束时间， 演练结束时核对降级后首 token 延迟 P99 是否仍在 1.2 秒以内。

演练结论以书面形式归档，包含当日峰值 QPS、P99 延迟曲线、触发的降级档位与恢复耗时。 如果演练未达到预期容量，下一次上线前必须补齐扩容或收紧预算，不能靠临时提高单卡并发上限硬扛。

9. 成本核算

成本按「每张卡每小时摊销 + 每次请求 token 数」两条线核算，每月出一次对比表： 实际上线卡时、平均单次 token 成本、缓存节省量。缓存节省量等于命中次数乘以平均单次成本， 只作为内部参考口径，不作为对外承诺。若平均单次成本连续两个月超出预算 10%， 需要评估量化精度或模型规模，而不是简单延长排队上限。