大模型技术里程碑摘录

本文件是为检索演示整理的**公开资料摘要**：只列被广泛记载的技术事件， 具体日期、作者与会议信息以原始论文和官方公告为准；未被收录的项目不代表不重要。

1. 架构与预训练

- 2017 年，Vaswani 等人发表《Attention Is All You Need》，提出 Transformer 架构， 用自注意力取代循环网络，成为后续大模型的共同底座。
- 2018 年，Devlin 等人提出 BERT，用双向预训练加微调的范式显著提升自然语言理解任务表现。
- 2020 年，Brown 等人提出 GPT-3，把参数规模推到千亿级，并系统展示少样本学习的能力。

2. 检索增强与工具调用

- 2020 年，Lewis 等人提出检索增强生成（RAG），把参数化记忆与非参数化检索结合， 在知识密集型任务上减少了对模型「记住事实」的依赖。
- 此后几年，检索增强从「先检索再生成」的单向流水线，逐步扩展为带查询改写、 重排序、上下文压缩与引用溯源的多阶段链路。
- 工具调用与函数调用把模型输出从纯文本扩展到结构化动作，使「模型决定何时检索」 成为智能体（Agent）设计的入口。

3. 开源与部署

- 2022 年底，面向大众的对话式产品把大模型推到公众视野，推理服务的容量与延迟 从此成为工程问题而不只是研究问题。
- 2023 年，Llama 系列以开放权重的方式发布，使本地部署与二次微调成为常规选项， 量化、蒸馏与推理引擎优化随之成为部署链路的标准配置。
- 中文检索场景普遍采用「密集向量 + 关键词」的混合召回，再用交叉编码器重排； 向量与重排模型都有面向中文的公开权重可选。

4. 治理

- 2023 年底，欧盟就《人工智能法案》达成临时政治协议；该法案于 2024 年 8 月正式生效， 按风险分级监管，并对通用模型提出透明度与文档要求。
- 对工程团队的实际影响是：数据来源、评测记录与变更留痕从「可选的好实践」 变成需要被审计的交付物。

5. 评测方法的转向

早期评测以单指标榜单为主，随后社区逐步转向「按能力分组的指标 + 人工复核」： 检索类系统需要分开看召回质量与生成忠实度，否则一个总分无法指出问题出在检索还是生成。 用大模型当评委可以扩展样本

量，但评委自身的抖动与偏好必须被记录， 组间差异小于评委抖动时不能宣称改进。

6. 推理与部署优化

- 量化（int8、int4）与蒸馏把大模型压进单机可部署的规模，是开放权重模型能被广泛使用的前提。
- 键值缓存复用、连续批处理与分页注意力显著提高同一张卡的并发序列数， 推理引擎本身由此成为一个独立的技术产品线。
- 投机解码用小模型草拟、大模型校验，用一次前向换多次 token 输出，降低首 token 之后的生成成本。

7. 中文检索生态

中文文档检索有两个长期难点：没有空格边界，词需要显式切分；同一概念在正式文档与口语提问之间 表述差异大。实践中常见的应对是关键词检索使用中文分词器，配合面向中文训练的密集向量模型， 再用交叉编码器重排。中文重排模型已有公开权重，可以直接在本地 CPU 上运行， 但延迟明显高于向量召回，需要按预算控制候选条数。

8. 智能体与工具接口

把模型输出约束为结构化工具调用之后，检索从「每问必答的一步」变成「模型可以主动调用的一次动作」。 由此带来的工程问题是：调用步数需要上限、失败需要回退路径、越权动作不能由模型自行决定，权限必须由服务端持有。智能体在多数问答场景下更慢也更贵， 是否值得使用应当用正确率、平均调用步数与成本三项数据说话，而不是凭概念判断。

9. 榜单的局限

公开榜单容易受到数据污染与题型偏差的影响：同一份资料既出现在训练语料又出现在评测集中时， 高分无法证明能力。工程团队更关心的是自己语料上的召回与忠实度， 因此自建小规模、可复核、带版本号的评测集，通常比追逐榜单名次更能反映系统真实水位。