# 多模态与评测笔记

技术专题整理：前四节讲多模态输入，后四节讲检索系统的评测方法。

## 1. 多模态输入的基本链路

图文混合输入通常走三步：先做版面分析，把页面切成文字块、表格与插图；再对文字块做识别； 最后把识别结果与图像特征一起送入模型。扫描件没有文字层，必须依赖识别，识别质量直接决定后续问答的上限。 纯文本检索系统接入扫描件时，最容易忽略的是页眉页脚与双栏排版带来的阅读顺序错误。

## 2. 图像成本

图像会按分辨率折算成 token，成本远高于同字数的文本。工程上要限制单次请求的图像数量与边长， 并在服务端记录每张图的折算 token 数。把整页截图直接交给模型通常是最贵且最不稳定的做法， 先用识别与版面分析把内容转成结构化的文本块，往往更便宜也更可控。

## 3. 表格与图表

表格理解的关键在于保留单元格与行列关系。直接把表格识别成一行文字，会让「哪一列是数值、哪一行是条件」 的信息丢失，问答时容易出现张冠李戴。图表则需要额外的数值读取步骤，读数误差应如实记录， 不能把估计值当作精确值写进答案。

## 4. 多模态检索

图文混合库的检索有两种做法：统一向量空间（图文共用一个编码器）与双路检索（文本走向量、图片走图向量）。 前者实现简单，后者召回更准但需要额外的融合与重排。无论哪种，引用都必须能回到具体的页面区域， 否则用户无法核对答案。

## 5. 检索与生成要分开评

一个总分无法指出问题出在检索还是生成。至少要拆成两层：检索层看答案所在的原文有没有被召回； 生成层看模型是否忠实于提供的材料。检索层的指标可以不调用模型、零成本重复运行； 生成层需要模型或人工，样本量小、噪声大，报告时必须带样本量与运行编号。

## 6. 判定方法的选择

用大模型当评委可以扩展样本量，但评委有偏好与抖动：同一个问题在温度为零时也可能得到不同分数。当组间差异小于评委抖动时，不能宣称改进。更客观的做法是为事实型问题标注原文唯一子串， 直接检查子串是否出现在最终上下文里；这种判定不依赖模型，可复现，缺点是无法评价表述质量。

## 7. 数据污染与指标饱和

如果评测材料本身出现在模型的训练数据里，高分不能证明能力。自建小语料能规避这一点， 但小语料很容易饱和：当整个库都能塞进 top-k 时，任何配置都能拿满分，指标失去区分度。 发现饱和信号（例如 recall@k 达到一点零）时，正确做法是扩大语料与题型，而不是反复微调参数。

## 8. 报告规范

任何指标都要带四样东西：样本量、语料版本、运行编号、以及已知限制。只报平均值不报分位数， 只报最好的一组不报全部配置，都属于选择性报告。改进声明必须能被第三方按同一脚本复现； 不能复现的改进，在工程上等于没有发生。