检索增强问答系统运维手册

> 本文件是**虚构的演示语料**：其中的制度、阈值与排班均为自编， 仅用于本地检索链路演示与评测。

1. 切块策略

文档入库采用父子两级切块：父块 800 字、重叠 20 字，用于交给大模型阅读；子块 200 字、重叠 20 字， 用于向量检索与关键词检索。子块的元数据只保存父块编号、来源文件名与权限档位，不保存父块全文， 父块正文单独存放在父块存储文件中，避免同一段文本按子块数量重复入库。

页眉页脚在切块前统一清洗，中文软换行需要拼接回整句，否则「相」「机」这类被换行拆开的词会污染关键词检索。

2. 检索与重排

召回阶段同时执行关键词检索与向量检索，各取前 20 条，按 0.5 与 0.5 权重融合并去重， 再用交叉编码器对融合结果打分，取前 10 条子块。上下文组装阶段按打分名次去重到父块， 最多取 3 个父块、总量不超过 3200 字；装不下的父块整块丢弃，绝不截断句子。

权限隔离在检索层完成：每一档在启动时编译独立的检索引擎，低档位候选集中物理上不存在高档位文档块， 而不是靠提示词要求模型「不要回答」。

3. 索引维护

全量重建排在每周日凌晨 3 点，重建前先快照。上传接口按来源替换旧文档块：先写入新块， 确认写入成功后再删除同名旧块，避免写入失败时把已有索引清空。切块结构变更必须连同索引集合一起升级版本号， 旧版本数据不做兼容读取，只允许重建。

4. 发布前的检索质量门槛

离线召回评测不调用付费接口，只用本地向量与重排模型。发布门槛为 recall@5 不低于 0.85， 且跨文档题目的 full@5 不低于 0.6。评测集扩题时必须保留旧题为子集、标注版本号， 参考答案由人工编写，禁止用模型输出当标准答案；通过门槛在跑之前定死，跑完不合预期如实记录。

5. 缓存与历史

会话历史与模型答案缓存共用一套内存数据库：历史按会话保留最近 10 轮，答案缓存有效期 7 天， 键统一加系统前缀。评测脚本使用独立键前缀并在结束时清理，禁止清理整个数据库， 否则会连带删除线上缓存。缓存只证明「同一次计算不再重复」，不能证明答案正确。

6. 值班与告警

问答服务值班时间为工作日 09:30 至 19:00，P1 故障 10 分钟内响应；告警条件为 五分钟内错误率高于 1%、或上下文为空的比例高于 2%。上下文为空比例升高通常意味着父块存储与索引不同步， 应优先检查父块文件而不是模型。

7. 溯源与引用

每个文档块至少携带来源文件名与父块编号，答案中的引用必须能回链到具体块。 页码尚未纳入元数据，因此现阶段引用只能写到「来源 + 块编号」，不允许凭推测补页码。 新增来源时同步更新来源清单，来源清单与索引一起重建，避免出现索引里有块、清单里没有文件的情况。 一旦对外提供引用功能，来源文件名必须是可读的真实名称，乱码文件名要在入库前修正。

8. 常见故障处置

- 答案普遍变成「资料中未提及」：先查父块存储能否加载，再查是否存在缺少父块编号的旧数据；父块文件损坏时服务应拒绝启动，而不是带着空字典继续跑。
- 召回明显变差：检查页眉页脚清洗规则是否失效、中文软换行是否重新出现， 这两类问题会让关键词检索把整句切成无意义片段。
- 延迟翻倍：先看重排候选条数是否变多，再看是否退化为 CPU 单线程； 重排成本随候选条数线性增长，与最终取回几条关系不大。
- 同名文件重传后答案错乱：确认旧块是否真的被替换，索引集合版本号是否一致。

9. 变更留痕

任何改变检索结果的调整（权重、切块尺寸、清洗正则、重排条数）都要写一条决策记录， 说明背景、决定、理由与代价，并把对应的评测目录写进去。没有评测目录支撑的改动只能算实验， 不能写进对外文档。评测结论必须带样本量与运行编号，样本量小于 10 时只描述现象、不下结论。 指标不达预期时如实记录，不允许事后调整通过门槛。

10. 容量与规模边界

本手册针对十万字级中文文档，千级文档块以内可以接受每次上传全量重建内存索引。 超过这个规模需要改成持久化关键词索引与后台入库队列，否则重建时间会挤占请求延迟。 这条边界要写进对外文档，避免别人用「支持多大文件」来追问一个没有被测量过的答案。